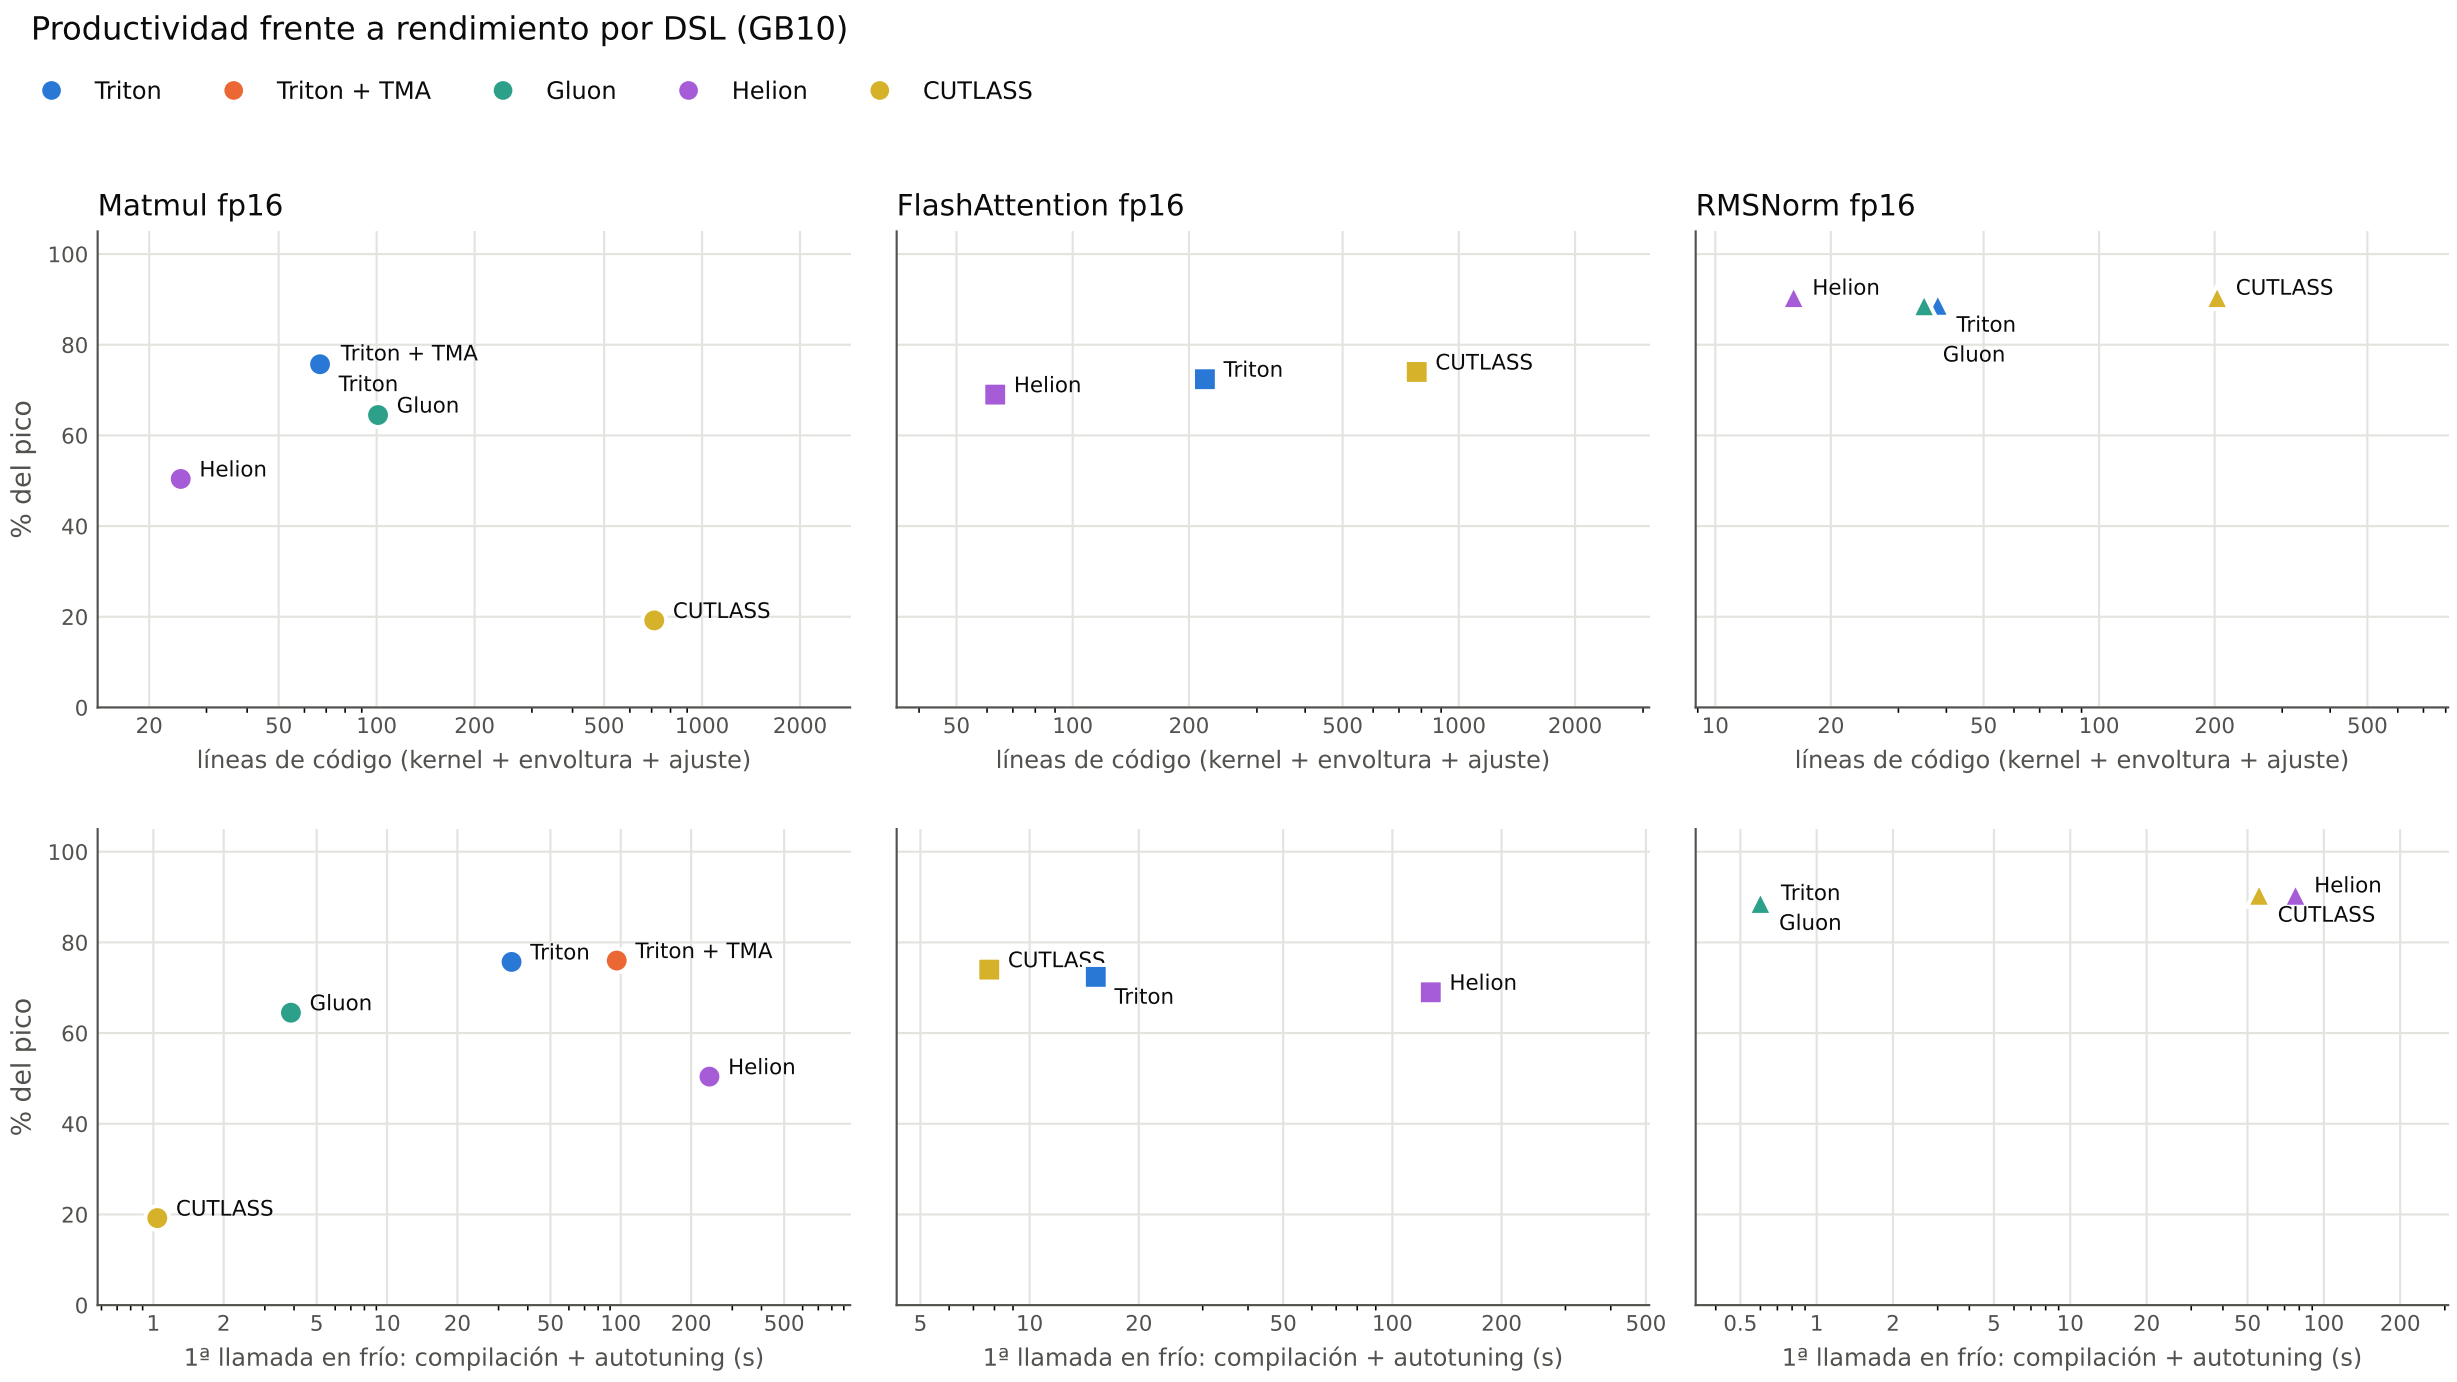

% del pico: de mma.sync f16→f32 (122.83 TFLOP/s) en matmul y atención; de memoria (273 GB/s) en RMSNorm. Una forma por algoritmo: matmul 8192³, FlashAttention B=4 H=32 N=4096 D=128, RMSNorm 16384×8192; fp16; GB10. Jobs 20841, 20842, 20843