NVIDIA GB10 (sm_121) — Compute Bound (TFLOP/s)

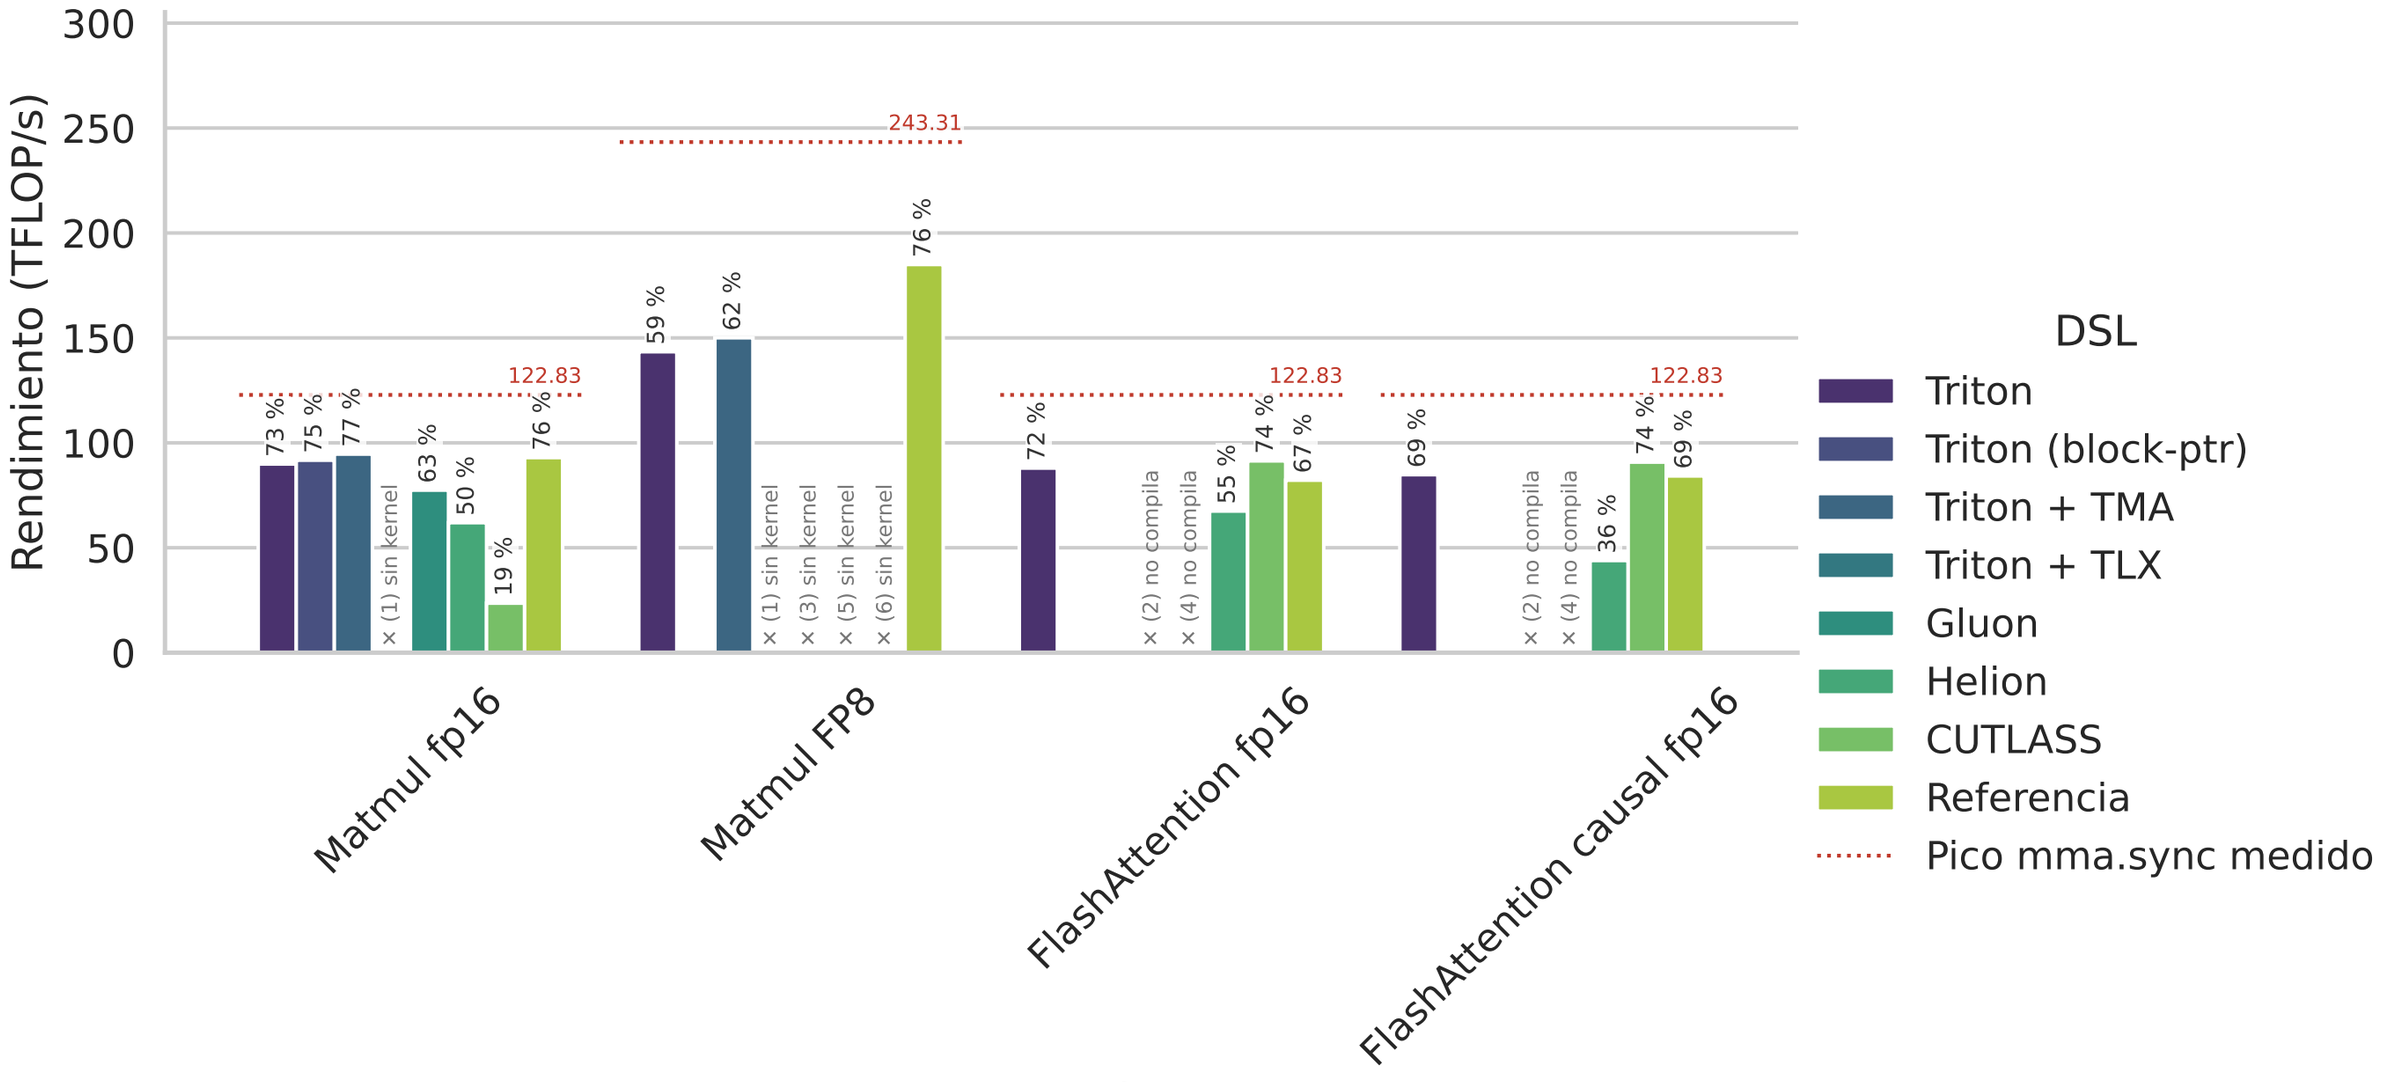

(1) sin kernel — Triton + TLX: no hay matmul en TLX
(2) no compila — Triton + TLX: los tutoriales de TLX usan wgmma/tcgen05 (Hopper, Blackwell de servidor)
(3) sin kernel — Gluon: no hay matmul FP8 en este DSL
(4) no compila — Gluon: el ejemplo oficial usa tcgen05: LLVM ERROR Cannot select tcgen05.wait.st
(5) sin kernel — Helion: no hay matmul FP8 en este DSL
(6) sin kernel — CUTLASS: el dense_gemm de CuTe solo admite fp16/bf16 (su FP8 en GeForce es MXFP8)