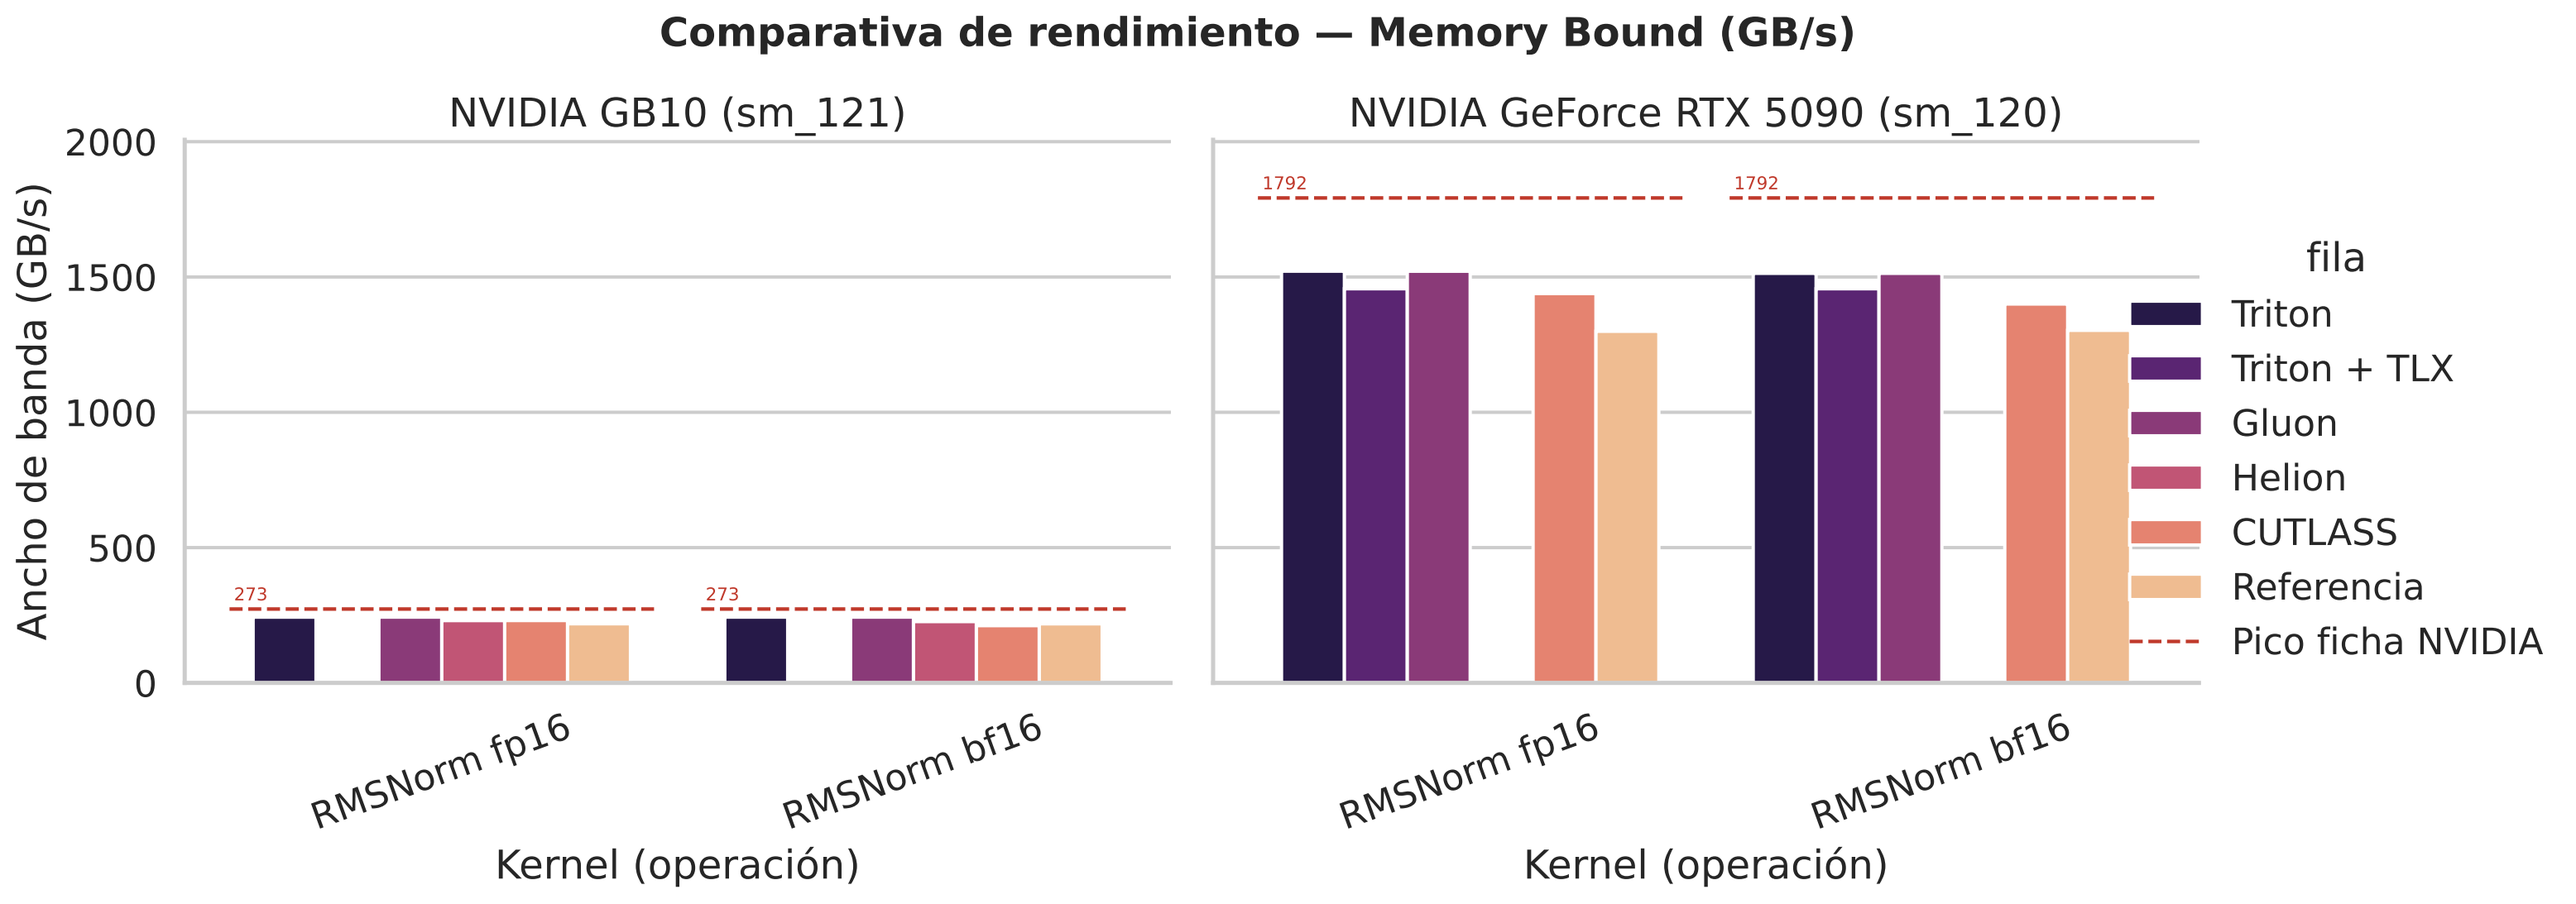
Comparativa de rendimiento — Memory Bound (GB/s)
NVIDIA GB10 (sm_121)
NVIDIA GeForce RTX 5090 (sm_120)
Ancho de banda (GB/s)
2000
1500
1000
500
0
273
273
1792
1792
RMSNorm fp16
RMSNorm bf16
RMSNorm fp16
RMSNorm bf16
Kernel (operación)
Kernel (operación)
fila
Triton
Triton + TLX
Gluon
Helion
CUTLASS
Referencia
Pico ficha NVIDIA